

CycleGan_Van_Gogh

2018 年 8 月 27 日



1 CycleGAN (梵谷風格轉換)

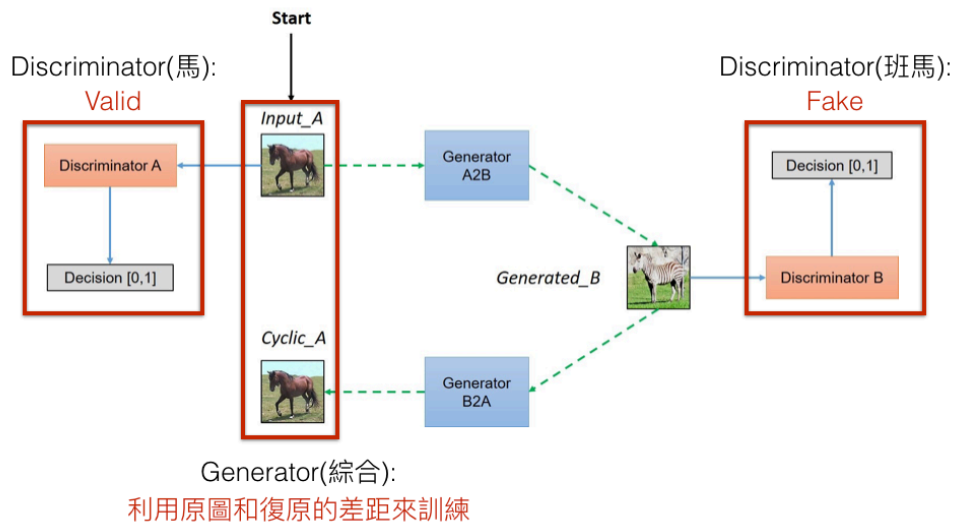
1.1 CycleGAN 介紹

CycleGAN 是一個很有趣的 GAN 的分支，普通的風格轉換你一定要有 **Pair** 的照片 (未上色和上色)，但 CycleGAN 你可以傳給他非 **Pair** 的照片，讓他完成兩種領域的互相轉換。

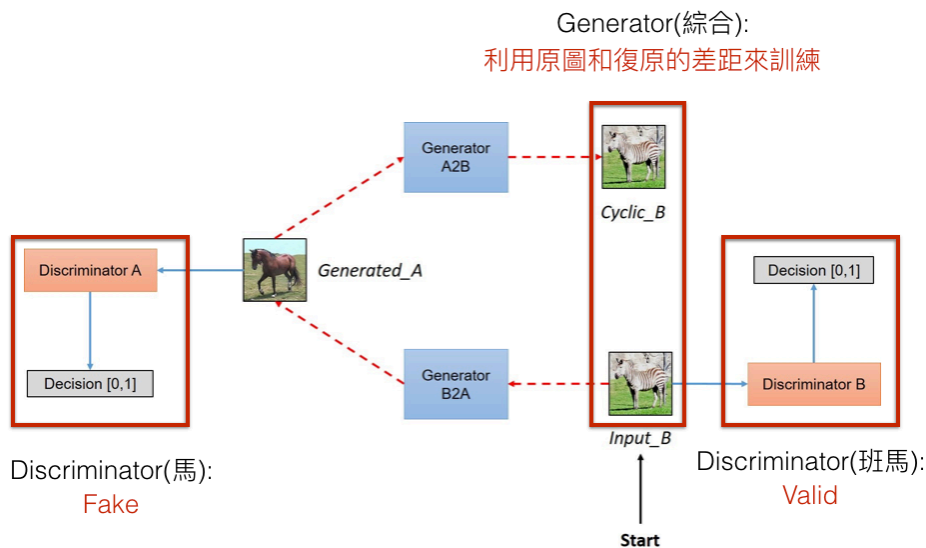
簡單來說，CycleGAN 最重要的就是循環！訓練出兩個 **Generator** 可以互相轉換對方的領域，也訓練兩個 **Discriminator**

1.2 Model

假設我們現在要完成馬和斑馬的互相轉換
我們先看輪迴的半邊，



再看另外半邊，



你會發現簡單來說！就是給你一張圖（先拿來訓練 A 分辨器的真），經過 AB 轉換做出來的 B（訓練 B 分辨器的假），再把假 B 轉換成 A（拿來訓練偽造器的參數）
再反過來做一次，兩次的循環合成一個完整的 GAN

1.3 Step1. 下載資料集

感謝網路上的梵谷和照片資料集

https://people.eecs.berkeley.edu/~taesung_park/CycleGAN/datasets/vangogh2photo.zip

```
In [1]: from keras.layers import Input
```

```

from keras.models import Model, Sequential
from keras.layers.core import Reshape, Dense, Dropout, Flatten
from keras.layers import Embedding, multiply, BatchNormalization, Concatenate, Input
from keras.layers.convolutional import UpSampling2D, Conv2D
from keras_contrib.layers.normalization import InstanceNormalization
from keras.layers.advanced_activations import LeakyReLU

import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
# 我們會使用到一些內建的資料庫, MAC 需要加入以下兩行, 才不會把對方的 ssl 憑證視為無效
import ssl
ssl._create_default_https_context = ssl._create_unverified_context

```

Using TensorFlow backend.

```

In [196]: from urllib.request import urlretrieve
          from os.path import exists
          url = "https://people.eecs.berkeley.edu/~taesung_park/" \
               "CycleGAN/datasets/vangogh2photo.zip"
          if not exists("vangogh2photo.zip"):
              print("還未下載過, 幫你下載資料集")
              urlretrieve(url, "vangogh2photo.zip")
          else:
              print("已下載過資料集")

```

已下載過資料集

```

In [3]: dataset_path = "vangogh2photo"
        from zipfile import ZipFile
        if not exists(dataset_path):
            z = ZipFile("vangogh2photo.zip", "r")
            print("還未解壓縮過, 幫你解壓縮資料集")
            z.extractall()
        else:
            print("已解壓縮過")

```

已解壓縮過

1.4 Step2. 確定資訊

我們先確定一下資料集的資訊(維度...等等)，順便把資料可視化一下

imageio 函式庫可以幫我們把圖片直接讀取成為 numpy array

所以我在這裡選擇使用 imageio 函式庫幫我閱讀 image，記得安裝一下

```
In [192]: from PIL import Image
          import os
          import numpy as np
          import random
          from imageio import imread

          a_train = []
          a_path = os.path.join(dataset_path, "trainA")
          # 走過 A 分類 (梵谷) 的所有照片
          for fname in os.listdir(a_path):
              img_path = os.path.join(a_path, fname)
              if not fname.startswith("."):
                  a_train.append(img_path)
          # 隨機選一個印出來
          i = random.randint(0, len(a_train) - 1)
          a_img = imread(a_train[i])
          plt.axis("off")
          plt.imshow(a_img)
          print("訓練資料 (梵谷) 維度:", a_img.shape)
```

訓練資料 (梵谷) 維度: (256, 256, 3)



```
In [195]: b_train = []
          b_path = os.path.join(dataset_path, "trainB")
          # 走過 B 分類 (風景) 的所有照片
          for fname in os.listdir(b_path):
              img_path = os.path.join(b_path, fname)
              if not fname.startswith("."):
                  b_train.append(img_path)

          i = random.randint(0, len(b_train) - 1)
          b_img = imread(b_train[i])
          plt.axis("off")
          plt.imshow(b_img)
          print("訓練資料 (風景) 維度:", b_img.shape)
```

訓練資料 (風景) 維度: (256, 256, 3)



1.5 Step2. 設計 Discriminator


1.5.1 全卷積

這裡使用全卷積，放棄了全連接層，對於圖片來說，全卷積可以正確地抓出圖片的隱含特徵

1.5.2 全卷積步長和視野窗


最新的概念裡，我們不使用池化層來減少計算量和縮小圖片了，因為池化其實就意味著放棄資料

我們現在喜歡使用帶步長的卷積層，像下圖的步長 2，一次走兩格，長寬自然就縮小了一半



大家通常會選用 (4, 4) 卷積窗和步長 2

因為如果你的步長不能整除卷積窗的話，會有貢獻不均衡的問題
我們把不均衡的例子放在下面




你會發現我們的步長 3 沒辦法整除卷積窗的大小 4

這樣就會有人只貢獻一次，很容易讓我們的特徵抓取變成一個不均衡的抓取

1.5.3 LeakyRelu

激活的函數，以前我們都選擇 `relu`，但是 `relu` 有個很嚴重的問題，就是到了死亡區斜率就變 0，那這次梯度下降就是 0，也就是不下降，而且 `weights` 來到死亡區很容易所有資料來到這神經元都會死亡，這時候我們就稱為這神經元『死亡』了

對於比較複雜的 GAN，網路極其脆弱，所以很容易就死亡了，這裡改進的方法就是改使用 `leakyrelu`



讓負區的斜率不為 0，但是是一個很小的值就好了

1.5.4 InstanceNormalization

我們上次在標準 GAN 裡有說過 Batch Normalization，簡單來說就是把一個 Batch 所有的資料標準化

目的是為了配合模型的 `weights`，並且也不會整團資料分佈在一個奇怪的地方

但是我們在做 CycleGAN 的時候，由於每一張圖片差距太大，所以我們改成使用 InstanceNormalization，對於每一張圖片 (而非一個 batch) 做標準化

In [7]: # 因為我們需要兩個 *Discriminator*，所以我們把它定義成函數

```
def build_discriminator():  
  
    def d_layer(layer_input, filters, f_size=(4, 4)):  
        d = Conv2D(filters, kernel_size=f_size,  
                    strides=2, padding='same')(layer_input)
```



```

        d = LeakyReLU(alpha=0.2)(d)
        d = InstanceNormalization()(d)
        return d

img = Input(shape=(256, 256, 3))

d1 = d_layer(img, 64)
d2 = d_layer(d1, 128)
d3 = d_layer(d2, 256)
d4 = d_layer(d3, 512)
validity = Conv2D(1, kernel_size=4, strides=1, padding='same')(d4)

return Model(img, validity)

```

1.6 Step2. 設計 Generator

generator 是卷積 (抓出 A 的真正特徵) + 反卷積 (以這些特徵構築 B) 的結果

1.6.1 反卷積

反卷積其實就是卷積的相反，這裡我們使用 UpSampling 層加上一次的卷積完成一次的反卷積

Size(2, 2) 的 UpSampling 是把每一個數字複製 4 個，變成 2 * 2 的同一數字

記得這裡卷積就必須把步長設定為 1 了
因為並沒有要改變我們的寬度

1.6.2 Concatenate 層

這裡比較特別一點，因為我們並不想讓整個 GAN 產生的結果跟原圖差十萬八千里
所以我們還會順便在反卷積的時候把相對應的卷積層當成 Embedding 傳入，希望這些特徵可以幫我們在 AB 轉換的時候還是維持原圖的特徵

In [6]: `def build_generator():`

```

def conv2d(layer_input, filters, f_size=(4, 4)):
    d = Conv2D(filters, kernel_size=f_size,
               strides=2, padding='same')(layer_input)
    d = LeakyReLU(alpha=0.2)(d)

```

```

        d = InstanceNormalization()(d)
        return d

def deconv2d(layer_input, skip_input, filters, f_size=(4, 4)):
    u = UpSampling2D(size=(2, 2))(layer_input)
    u = Conv2D(filters, kernel_size=f_size,
               strides=1, padding='same')(u)
    u = LeakyReLU(alpha=0.2)(u)
    u = InstanceNormalization()(u)
    u = Concatenate()([u, skip_input])
    return u

d0 = Input(shape=(256, 256, 3))

d1 = conv2d(d0, 32)
d2 = conv2d(d1, 64)
d3 = conv2d(d2, 128)
d4 = conv2d(d3, 256)

u1 = deconv2d(d4, d3, 128)
u2 = deconv2d(u1, d2, 64)
u3 = deconv2d(u2, d1, 32)
u3 = deconv2d(d2, d1, 32)

u4 = UpSampling2D(size=(2, 2))(u3)
output_img = Conv2D(3, kernel_size=(4, 4),
                   strides=1, padding='same',
                   activation='tanh')(u4)

return Model(d0, output_img)

```

1.7 Step3. 建立模型並編譯

1.7.1 調整 Adam 優化器

由於我們的 GAN 非常脆弱，所以我希望能稍微讓我們的優化器再調整一下

Adam[\[source\]](#)

```
keras.optimizers.Adam(lr=0.001, beta_1=0.9, beta_2=0.999, epsilon=None, decay=0.0, amsgrad=False)
```

Adam optimizer.

Default parameters follow those provided in the original paper.

Arguments

- **lr**: float >= 0. Learning rate.
- **beta_1**: float, 0 < beta < 1. Generally close to 1.
- **beta_2**: float, 0 < beta < 1. Generally close to 1.
- **epsilon**: float >= 0. Fuzz factor. If `None`, defaults to `K.epsilon()`.
- **decay**: float >= 0. Learning rate decay over each update.
- **amsgrad**: boolean. Whether to apply the AMSGrad variant of this algorithm from the paper "On the Convergence of Adam and Beyond".

通常我們不希望我們的 **Discriminator** 變好的太快，因為 **Generator** 就會無所適從，不知道如何變好

所以我們會把 **learning rate**(更新 **weights** 前面成的常數) 變小一點，根據大家的經驗法則，0.0002 是一個很不錯的學習速率

那這邊我通常也會把動量 (**Adam** 是基於動量的一個優化器) 調整小一點

總之，我這裡希望放慢一點鑑賞家變慢的速度

1.7.2 Loss

因為我們的 **Discriminator** 使用的是全卷積，所以最後還是輸出有寬和高

那我們就不能用以往的 **Binary CrossEntropy** 來判定了，所以我們改用 **Mean Square Error**(距離平方再開根號) 來當作我們的損失

```
In [8]: from keras.optimizers import Adam
        op = Adam(0.0002, 0.5)
        d_A = build_discriminator()
        d_A.compile(loss='mse',
                    optimizer=op,
                    metrics=['accuracy'])
        d_A.summary()
```

Layer (type)	Output Shape	Param #
=====		
input_1 (InputLayer)	(None, 256, 256, 3)	0

conv2d_1 (Conv2D)	(None, 128, 128, 64)	3136

```

-----
leaky_re_lu_1 (LeakyReLU)      (None, 128, 128, 64)      0
-----
instance_normalization_1 (In (None, 128, 128, 64)      2
-----
conv2d_2 (Conv2D)              (None, 64, 64, 128)      131200
-----
leaky_re_lu_2 (LeakyReLU)      (None, 64, 64, 128)      0
-----
instance_normalization_2 (In (None, 64, 64, 128)      2
-----
conv2d_3 (Conv2D)              (None, 32, 32, 256)      524544
-----
leaky_re_lu_3 (LeakyReLU)      (None, 32, 32, 256)      0
-----
instance_normalization_3 (In (None, 32, 32, 256)      2
-----
conv2d_4 (Conv2D)              (None, 16, 16, 512)      2097664
-----
leaky_re_lu_4 (LeakyReLU)      (None, 16, 16, 512)      0
-----
instance_normalization_4 (In (None, 16, 16, 512)      2
-----
conv2d_5 (Conv2D)              (None, 16, 16, 1)        8193
=====
Total params: 2,764,745
Trainable params: 2,764,745
Non-trainable params: 0
-----

```

```

In [9]: d_B = build_discriminator()
        d_B.compile(loss='mse',
                    optimizer=op,
                    metrics=['accuracy'])
        d_B.summary()
-----

```

Layer (type)	Output Shape	Param #
input_2 (InputLayer)	(None, 256, 256, 3)	0
conv2d_6 (Conv2D)	(None, 128, 128, 64)	3136
leaky_re_lu_5 (LeakyReLU)	(None, 128, 128, 64)	0
instance_normalization_5 (In	(None, 128, 128, 64)	2
conv2d_7 (Conv2D)	(None, 64, 64, 128)	131200
leaky_re_lu_6 (LeakyReLU)	(None, 64, 64, 128)	0
instance_normalization_6 (In	(None, 64, 64, 128)	2
conv2d_8 (Conv2D)	(None, 32, 32, 256)	524544
leaky_re_lu_7 (LeakyReLU)	(None, 32, 32, 256)	0
instance_normalization_7 (In	(None, 32, 32, 256)	2
conv2d_9 (Conv2D)	(None, 16, 16, 512)	2097664
leaky_re_lu_8 (LeakyReLU)	(None, 16, 16, 512)	0
instance_normalization_8 (In	(None, 16, 16, 512)	2
conv2d_10 (Conv2D)	(None, 16, 16, 1)	8193
Total params: 2,764,745		
Trainable params: 2,764,745		
Non-trainable params: 0		

1.7.3 合併模型

跟傳統 GAN 一樣，創立一個合併模型，詳細步驟我們註解在程式碼上

```
In [10]: # 建立 Generator, 不過不用編譯, 因為我們沒有要訓練他
g_AB = build_generator()
g_BA = build_generator()
# 輸入圖片的大小
img_A = Input(shape=(256, 256, 3))
img_B = Input(shape=(256, 256, 3))

# 創造偽作
fake_B = g_AB(img_A)
fake_A = g_BA(img_B)
# 偽作再偽造回原作
reconstr_A = g_BA(fake_B)
reconstr_B = g_AB(fake_A)
# 這裡比較特別, 我們希望 A 類的圖片就算丟進 A->B 轉換還是維持
img_A_id = g_BA(img_A)
img_B_id = g_AB(img_B)

# 記得在合併模型的時候我們要固定住 Discriminator
d_A.trainable = False
d_B.trainable = False

# 對兩個偽作接上 Discriminator
valid_A = d_A(fake_A)
valid_B = d_B(fake_B)

# 這裡我們由於有多個 output, 所以也要接多個 loss
# mse 會對預測很差的做很大的懲罰
# 對於畫, 我們沒有要給很大的懲罰, 所以我們選擇 mae
combined = Model(inputs=[img_A, img_B],
                  outputs=[valid_A, valid_B,
                           reconstr_A, reconstr_B,
                           img_A_id, img_B_id])
combined.compile(loss=['mse', 'mse',
                      'mae', 'mae',
```

```

        'mae', 'mae'],
        loss_weights=[ 1, 1,
                        10, 10,
                        1, 1],
        optimizer=op)
combined.summary()

```

```

-----
Layer (type)                Output Shape          Param #    Connected to
-----
input_6 (InputLayer)        (None, 256, 256, 3)  0
-----
input_5 (InputLayer)        (None, 256, 256, 3)  0
-----
model_4 (Model)             (None, 256, 256, 3)  70281     input_6[0][0]
                                model_3[1][0]
                                input_5[0][0]
-----
model_3 (Model)             (None, 256, 256, 3)  70281     input_5[0][0]
                                model_4[1][0]
                                input_6[0][0]
-----
model_1 (Model)             (None, 16, 16, 1)    2764745    model_4[1][0]
-----
model_2 (Model)             (None, 16, 16, 1)    2764745    model_3[1][0]
=====
Total params: 5,670,052
Trainable params: 140,562
Non-trainable params: 5,529,490
-----

```

1.8 Step4. 訓練模型

由於我們是全卷積，所以必須把寬高都填滿 1，那最後輸出只有一個通道，所以是 (16, 16, 1)

```

In [197]: patch = int(256 / 2**4)
          disc_patch = (patch, patch, 1)
          disc_patch

```

Out[197]: (16, 16, 1)

因為一次訓練一張圖，所以我們只需要 (1, 16, 16, 1) -> (一張圖, 寬, 高, 通道數)

```
In [199]: valid = np.ones((1,) + disc_patch)
         fake = np.zeros((1,) + disc_patch)
```

大概訓練了數萬次，只取最後的幾次

```
In [189]: batch_size = 1
         train_count = 5
         d_loss_list = []
         g_loss_list = []
         for train in range(0, train_count):
             dash = "-" * 15
             print(dash, "Train", train, dash)

             ida = np.random.randint(0, len(a_train), batch_size)
             idb = np.random.randint(0, len(b_train), batch_size)

             imgs_A = []
             imgs_B = []
             for i in ida:
                 imgs_A.append((imread(a_train[i]) - 127.5)/127.5)
             for i in idb:
                 imgs_B.append((imread(b_train[i]) - 127.5)/127.5)
             imgs_A = np.array(imgs_A)
             imgs_B = np.array(imgs_B)

             fake_B = g_AB.predict(imgs_A)
             fake_A = g_BA.predict(imgs_B)

             d_A.trainable = True
             d_B.trainable = True
             dA_loss_real = d_A.train_on_batch(imgs_A, valid)
             dA_loss_fake = d_A.train_on_batch(fake_A, fake)
             dA_loss = 0.5 * np.add(dA_loss_real, dA_loss_fake)
```



```

dB_loss_real = d_B.train_on_batch(imgs_B, valid)
dB_loss_fake = d_B.train_on_batch(fake_B, fake)
dB_loss = 0.5 * np.add(dB_loss_real, dB_loss_fake)

# Total discriminator loss
d_loss = 0.5 * np.add(dA_loss, dB_loss)

d_A.trainable = False
d_B.trainable = False
g_loss = combined.train_on_batch([imgs_A, imgs_B],
                                  [valid, valid,
                                   imgs_A, imgs_B,
                                   imgs_A, imgs_B])

dash = "-" * 15
print("Discriminator loss:", d_loss)
print("Generator loss:", g_loss)
d_loss_list.append(d_loss)
g_loss_list.append(g_loss)

----- Train 0 -----
Discriminator loss: [0.02281462 1.          ]
Generator loss: [3.9857652, 0.89864177, 0.7574793, 0.101250775, 0.072771996, 0.2323237, 0.35709]
----- Train 1 -----
Discriminator loss: [0.2055629 0.75          ]
Generator loss: [3.002908, 0.97745234, 0.105900034, 0.09675653, 0.07022899, 0.1215199, 0.12818]
----- Train 2 -----
Discriminator loss: [0.02731891 1.          ]
Generator loss: [3.7201955, 1.074858, 0.77537143, 0.05991071, 0.09943257, 0.14868948, 0.127843]
----- Train 3 -----
Discriminator loss: [0.10703883 0.79589844]
Generator loss: [3.515755, 1.0189565, 0.6486736, 0.09558727, 0.058565624, 0.22159313, 0.085002]
----- Train 4 -----
Discriminator loss: [0.10798818 0.86328125]
Generator loss: [3.2700064, 1.074095, 0.349965, 0.06928012, 0.07942289, 0.2272602, 0.13165641]


```

1.9 Step5. 看看結果

原本的畫

```
In [63]: idx = random.randint(0, len(a_train) - 1)
         drawing = imread(a_train[idx])
         plt.imshow(drawing)
```

```
Out [63]: <matplotlib.image.AxesImage at 0x1355bb208>
```

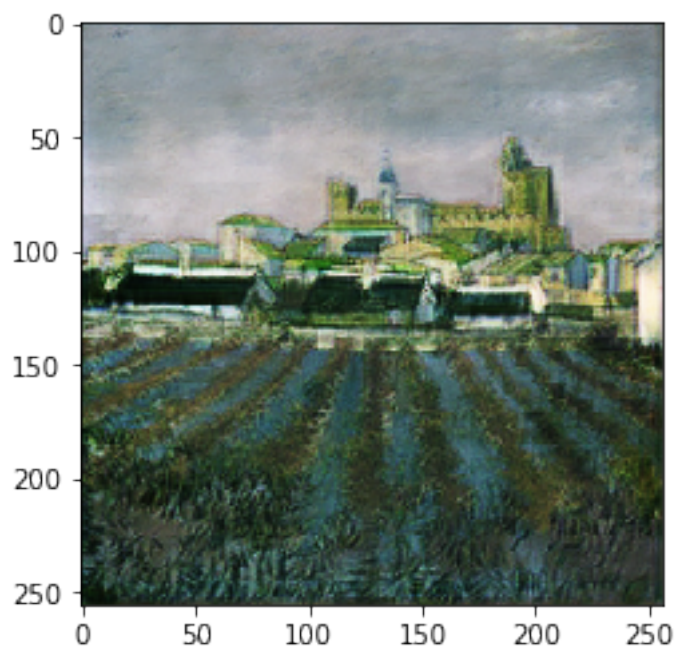


```
In [64]: drawing_shaped = (drawing - 127.5)/127.5
```

轉換成風景後

```
In [190]: fake_scenery = g_AB.predict(np.array([drawing_shaped]))
          fake_scenery = 0.5 * fake_scenery + 0.5
          plt.imshow(fake_scenery[0])
```

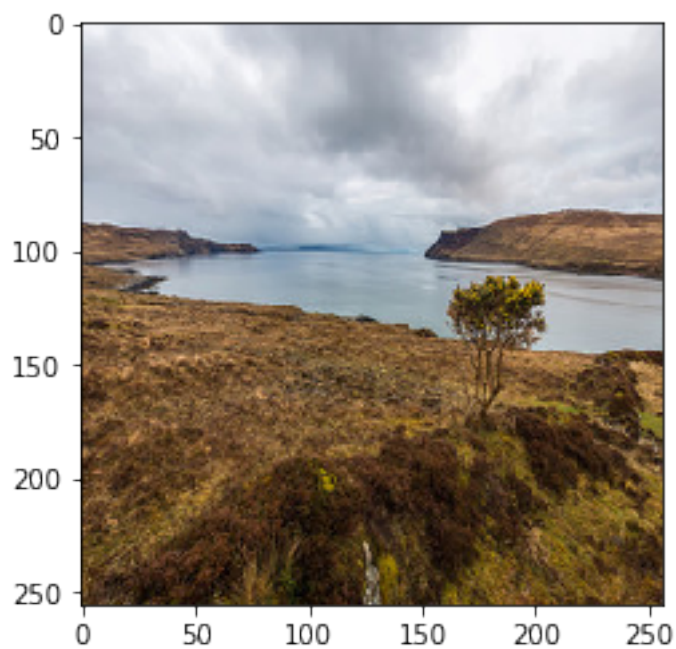
```
Out [190]: <matplotlib.image.AxesImage at 0x11e49b9e8>
```



原本的風景

```
In [128]: idx = random.randint(0, len(b_train) - 1)
          scenery = imread(b_train[idx])
          plt.imshow(scenery)
```

```
Out[128]: <matplotlib.image.AxesImage at 0x135fcb208>
```

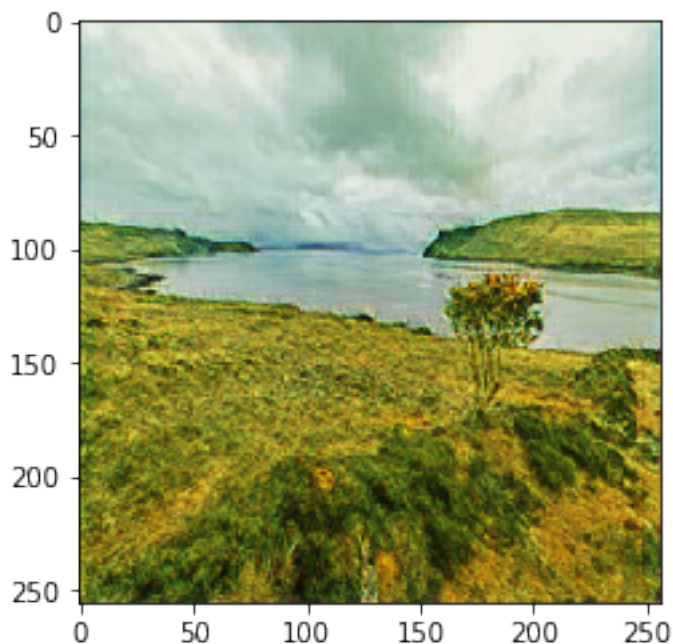


```
In [129]: scenery_shaped = (scenery - 127.5)/127.5
```

轉換成梵谷風

```
In [191]: fake_drawing = g_BA.predict(np.array([scenery_shaped]))  
fake_drawing = 0.5 * fake_drawing + 0.5  
plt.imshow(fake_drawing[0])
```

```
Out[191]: <matplotlib.image.AxesImage at 0x139cb5390>
```



列出多一點，你可以看得出，有些轉換隱隱有梵谷的影子了

```
In [181]: drawbatch = 5
          idx = np.random.randint(0, len(b_train), drawbatch)

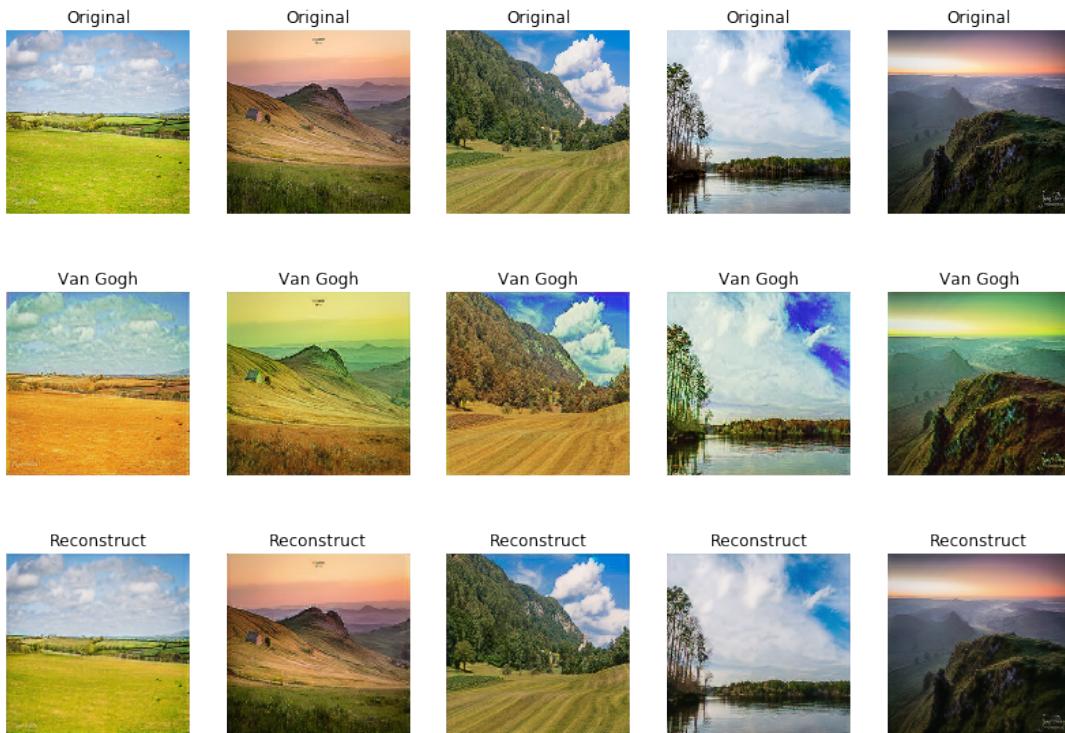
          scenery_batch = []
          drawing_batch = []
          reconstruct_batch = []

          for i in idx:
              scenery_i = imread(b_train[i])
              scenery_i_shaped = (scenery_i - 127.5)/127.5
              scenery_batch.append(scenery_i)
              fake_drawing_i = g_BA.predict(np.array([scenery_i_shaped]))
              reconstruct_i = g_AB.predict(fake_drawing_i)
              fake_drawing_i = 0.5 * fake_drawing_i + 0.5
              drawing_batch.append(fake_drawing_i[0])
              reconstruct_i = 0.5 * reconstruct_i + 0.5
              reconstruct_batch.append(reconstruct_i[0])
```

```

plt.figure(figsize = (14,10))
for (i, draw) in enumerate(scenery_batch):
    plt.subplot(3, drawbatch, i + 1)
    plt.title("Original")
    plt.axis("off")
    plt.imshow(draw)
for (i, draw) in enumerate(drawing_batch):
    plt.subplot(3, drawbatch, drawbatch + (i + 1))
    plt.title("Van Gogh")
    plt.axis("off")
    plt.imshow(draw)
for (i, draw) in enumerate(reconstruct_batch):
    plt.subplot(3, drawbatch, 2 * drawbatch + (i + 1))
    plt.title("Reconstruct")
    plt.axis("off")
    plt.imshow(draw)

```



```
In [20]: d_A.save("davangogh.h5")
         d_B.save("dbvangogh.h5")
         g_AB.save("gabvangogh.h5")
         g_BA.save("gbavangogh.h5")
         combined.save("combinedvangogh.h5")
```